


從開放資料到 AI-READY 國際實踐研究：
賦能資料管理者，促進公民與政府的對話

FROM OPEN DATA TO AI-READY DATA:

INTERNATIONAL PRACTICES FOR EMPOWERING DATA STEWARDS AND ADVANCING CITIZEN-GOVERNMENT DIALOGUE



OpenCulture
Foundation_



FRIEDRICH NAUMANN
FOUNDATION For Freedom.

Taiwan / Global Innovation Hub

出版資訊

本研究報告由臺灣財團法人開放文化基金會發起，並由德國弗里德里希諾曼自由基金會在台辦事處 / 全球創新中心合作支持。同時，感謝國內外受訪者於研究過程中，分享各國案例背後的執行細節與實務經驗；亦感謝在地訪談者，依其於不同政府機關與社群中的實際參與經驗，協助本報告在彙整階段釐清研究限制、精進分析方向，並為本會後續推動相關倡議提供具體可行的行動基礎。

專案名稱： From Open Data to AI-Ready Data: International Practices
for Empowering Data Stewards and Advancing Citizen-Government Dialogue

主要著者： 財團法人開放文化基金會 (OCF)

共同著者： FNF 德國弗里德里希諾曼自由基金會 在台辦事處 / 全球創新中心

總編輯： Dong Po Deng 鄧東波

助理編輯： Ian Liu 劉俊彥、Rosalind Liu 劉澄真

英文翻譯： Stephen Ma 馬思揚

英文校對： Peixing Liao 廖珮杏 Warren Liu 劉維人

設計編排： Muka Wang 王俊凱

責任編輯： Shin-Yin Li 李欣穎

國際訪談：

Carlos Alonso, ImpulsaDATA Project, 西班牙

Ingo Hinterding, Parla, 德國

Lukas Gienapp, Martin Potthast, The German Commons, 德國

Manuel Faysse, CroissantLLM, 法國

Try Thy, Vimoil Ourn, Wen-Ling (Amy) Lai, Open Development Cambodia (ODC), 柬埔寨

在地訪談： 王向榮、林哲豪、黃亮勳、曾憲立、連丁幼

本報告由 OCF 與 FNF 合作發行，並以 CC BY 4.0 釋出。

如需引用此報告，請使用以下格式：

開放文化基金會、弗里德里希諾曼自由基金會在台辦事處 / 全球創新中心 (2026)。AI-Ready 開放資料實踐研究：賦能資料管理者，促進公民與政府對話。

目錄


精選摘要	4
第一章 緒論	5
1.1.1 傳統開放資料定義怎為 AI 所用	6
1.1.2 提升至「AI-Ready 資料」的意涵	6
1.1.3 開放資料運用於 AI-Ready 時的注意事項	6
1.2.1 產業發展 創造價值	7
1.2.2 文化保存 穩固主權	7
第二章 世界各地 AI-READY 開放資料發展	8
2.1.1 世界主要國家的發展	8
2.1.2 臺灣近期發展	8
2.2.1 案例分析架構	9
2.2.2 案例挑選與定位	10
2.3.1 西班牙 ImpulsaDATA 計畫 案例	10
2.3.2 德國 The German Commons 案例	10
2.3.3 柬埔寨 Open Development Cambodia 案例	11
2.3.4 德國 Parla 案例	11
2.3.5 法國 CroissantLLM 案例	11
第三章：開放資料究竟怎麼變成 AI-READY	12
3.1.1 有系統地 OCR 轉換與文件傳承	13
3.1.2 注意不同時代字體差異造就的可讀性差異	13
3.1.3 配合不同資料狀態選擇適合 OCR 策略及格式	13
3.1.4 資料產製留存即思考機器可讀性與開放授權	13
3.2.1 四次內的隱私風險控制	14
3.2.2 有語境脈絡地設計去敏感代碼	14
3.2.3 弱勢文化的隱私議題	14
3.2.4 小結	14
3.3.1 有意識地設計語料比例與釋出開放工具	15
3.3.2 意識到時間維度造成的偏見	15
3.3.3 多語系的多樣性支援	15
3.3.4 透過流程設計減少偏見	15
3.3.5 小結	15

第四章：推動 AI-READY DATA 需要哪些環境、政策與調適行動_____ 16

4.1.1 清晰的開放資料法律框架 _____	16
4.1.1.1 支持政府資訊公開的政策或具體立法 _____	16
4.1.1.2 正確選擇適切的條款 _____	17
4.1.1.3 簡明連貫的法規架構 _____	17
4.1.1.4 小結 _____	17
4.1.2 展現開放資料價值促進實質合作 _____	17
4.1.2.1 政府需求導向的關係建立 _____	17
4.1.2.2 正向公私協力案例促進立法 _____	17
4.1.2.3 小結 _____	17
4.2.1 建立政府內部跨機關的制度化協作 _____	18
4.2.2 輔以下而上模式整合需求 _____	18
4.2.3. 資料主題性選擇 _____	18
4.2.3.1 注意該資料主題的複雜性 _____	18
4.2.3.2 強調資料應用，降低政府機關對該主題資料開放的擔憂 _____	18
4.2.4 小結 _____	19

第五章 總結與 AI 開放資料推動藍圖 _____ 20

5.2.1 賦能公務員自身的工作 _____	23
5.2.2 賦能民眾的知情與參與 _____	23
5.2.3 賦能 AI 的文化多樣性 _____	23
5.2.3 邁向可持續的開放資料生態系 _____	24



精選摘要

隨著人工智慧的快速發展，傳統開放資料正面臨根本性的轉型，逐步邁向「AI-ready 開放資料」。然而，現行政府開放資料的結構與格式，並不一定完全符合 AI 訓練與應用需求。為協助政府與公民社會將傳統開放資料轉化為 AI-ready 資料，本報告透過西班牙、德國、柬埔寨與法國等國際實務案例，提出從資料源頭重新設計政府資料釋出格式、促進 AI 創新應用的實務模式。

- 0** 政府開放資料對 AI 模型開發者而言具有重要價值，因其通常具有較低的個人資料與著作權風險，且具備可近用性。然而，根據 McKinsey & Company 的報告，許多大型語言模型研究者仍需花費約 80% 的時間，將政府開放資料轉換為適合 AI 訓練的格式。這顯示政府需要被賦能，從傳統開放資料的釋出模式，進一步轉向 AI-ready 開放資料。
- 1** 從既有文件格式轉換為機器可讀標準，並建立嚴謹的資料架構，是各國邁向 AI-ready 開放資料最基礎且關鍵的起點。此一轉型可大幅降低目前拖慢國家科技發展的技術負擔，並減輕企業在資料處理上的成本壓力。
- 2** 然而，僅建立與開放資料相關的法制架構仍不足以實現 AI-ready 資料。政府亦需改善或建立清楚且完整的個人資料保護與智慧財產權法制度，並進一步協調不同法制之間的適用關係。這些制度若彼此衝突，往往會阻礙資料走向 AI-ready 的進程。
- 3** 此外，採用國際開放授權標準，對於因應複雜法規環境至關重要，能有效降低機構風險與開發者的交易成本。為確保資料的長期可用性與可靠性，政府機關應由被動揭露轉向主動釋出，透過集中式平台進行管理，並採用結合在地基礎設施與公共儲存資源的多層次韌性儲存策略。
- 4** 若要說服政府將資料轉化為 AI-ready 資料，或進一步開放更多資料，關鍵在於透過多種方式建立信任。在尚未具備完整開放資料法制架構的環境中，倡議組織可先從理解政府需求開始，選擇較低敏感度但具潛在影響力的主題作為切入點，藉此開啟對話，並為未來合作建立基礎。
- 5** 在公務員對資料開放或 AI 應用仍感到猶豫的情況下，更有效的策略，是先展現協助解決問題的意願，從行政內部痛點著手。例如 CityLAB 透過工作坊邀請公務員提出實際工作中遇到的問題，並共同設計可回應這些問題的 AI 工具。這類非對抗式倡議與客製化技術支援，有助於降低制度轉型初期的阻力。
- 6** AI-ready 開放資料將成為促進社會與民主發展的基礎設施。對公務員而言，優化資料治理可提升內部行政效率，使資料釋出從被動、裁量性的任務，轉變為制度核心職能；對公民而言，結構化且具互通性的資料，能結合 AI 工具分析複雜的政府紀錄，降低技術門檻，強化公民參與與監督能力。
- 7** 即使現有技術工具已能協助將 PDF 等政府開放資料轉換為機器可讀格式，實務經驗仍顯示，此一過程往往會遺失大量資訊，特別是原始文件或文章中的結構、脈絡與邏輯。因此，政府仍應優先以機器可讀格式釋出資料。對於數值或統計資料，CSV 是較理想的格式；對於文字型資料，Markdown (MD) 則更適合作為開放釋出的基礎格式。
- 8** 面對 AI 模型可能造成的資料邊緣化與風險擴散，資料語料化過程也必須更加謹慎，確保個人資料與隱私資訊不被納入訓練語料。由於資料一旦進入模型後，將難以徹底移除，無論政府最終是否決定釋出資料，都應先進行測試，以確認資料中是否包含個人資料。若開發者擔心移除個人資料會破壞資料語意或影響模型訓練，可考慮使用固定格式的替代詞彙，在保留語句意義的同時替換敏感資訊。
- 9** 在文化層面，建立具主權性的 AI 語料體系，對於避免語言邊緣化與時間偏誤至關重要。高品質的在地資料有助於確保國家脈絡被正確保存，避免外來文化框架主導，並在數位時代維持多元文化的可見性。

本報告將邁向 AI-ready 開放資料定位為一項集體性的公共基礎建設工程，有賴政府、學界與公民社會的長期合作。為推動此一轉型，本報告亦提出可操作的行動模組與實踐路徑，最終目標是在 AI 時代建立具韌性的開放資料生態系。

AI-READY 開放資料小知識

常見疑問

機關需要採用新工具
來釋出 AI-Ready 的開放資料？

不需要。各機關只需按既有流程上傳開放資料，
直接將文件、試算表等原始格式檔案（如 .odt）釋出即可。

額外處理 AI-Ready 的開放資料需求
將讓機關人力更吃緊？

流程設計正確的情況下，開放資料能夠等同 AI-Ready 開放資料，
無需增加額外資訊人力。

資料更新頻率是否會因此提升？

不會，AI-Ready 開放資料對「即時性」的要求
在於明確標注資料產出時間，而非即時更新所有資訊。

實際情況

第一章 緒論

這份報告旨在介紹從開放資料到 AI-Ready 資料這條發展路徑，其能為創新與民主治理帶來什麼貢獻，如何達成，以及世界各國的實踐為何，並從這些經驗歸納出法規與實務上的能促進更多 AI-Ready 資料的方法。

本研究期待公務人員閱讀過這份報告後，能夠理解 AI-Ready 資料的產出，並不大幅度影響現有資料開放流程，可於既有的資訊人力或軟體工具下，回頭更關注原始資料格式，及其他更新時間註記這些本於開放資料建置時的基本要求。

為鼓舞各國公務機關勇於開放高品質資料，提升全球跨文化與國家的 AI-Ready 資料量，以促進人類多元文明發展。本研究希望呈現，開放資料如何微調建置與標註方式，以期在 AI 時代能更便利地合法合規地利用，展現其價值。

同時，對於任何公民科技或開源社群的參與者，本研究也很樂見您藉由閱讀認識不同國家在 AI-Ready 資料的公私協力發展歷程後，參考其經驗、使用工具或合作方式，將本份研究輔助用於您與公務機關對話。

1.1 為什麼需要這份案例研究

隨著 AI 技術在 2022 年後的極速發展，LLM 對於獲取資料以進行訓練的需求逐步上升。長期以來，政府開放資料因具備公共性、可近用性，以及相對明確的授權條件，常被視為 AI 訓練的重要資料來源之一。同時，許多國家亦將 AI 視為提升國家競爭力與發展潛力的關鍵要素，使開放資料與 AI 發展之間逐漸形成一種相互影響、彼此依賴的治理循環。

然而，傳統開放資料在其在建置時，內容結構與資料格式等面向，未必能直接回應不同 AI 訓練與應用的需求。如何在維持開放資料持續釋出的同時，加速 AI 訓練流程，並確保資料在品質、結構與規格上更適合被 AI 系統理解與使用，成為各國政府與資料治理者必須面對的重要課題。怎樣從既有開放資料的提升到 AI-Ready 可用的開放資料，是本研究嘗試檢視各國的案例中，找到其可用、可參考的實務方向。

1.1.1 傳統開放資料定義怎為 AI 所用

論及傳統開放資料於 AI 的運用，如果以 Tim Berners-Lee (2006)^[1] 的開放資料評等定義的一星等級資料為比較的基準，會發現基礎即是以「開放」授權為核心達到基礎的近用。到了二星、三星的機器可讀及採開放格式，因不同運用需求，而採不同格式資料尤為重要。以 LLM 大型語言訓練需求為例，過往臺灣政府資料開放平臺中各機關以釋出 CSV 格式為大宗，但因許多欄位名稱、詮釋資料 (Metadata) 的建置不精準，導致在訓練過程中，易導致訓練出來的模型解讀資料時語意模糊；反之 LLM 所需的 Markdown (MD) 格式甚至被稱之 LLM 的原生語言，則可以方便處理大量文章、報告類型的文字的結構化。同樣地，在四星、五星評等下的開放資料，政府機關如要產製有其門檻，但其賦予固定 URI 位置或具備語意的鏈結資料網絡，這些的特性亦是發展多元 AI 助理時，極具價值的技術基礎。

另外再以多模態 AI 的訓練需求為例：圖片、聲音、地圖圖資、多媒體的資料，亦是發展成主權 AI 所需承載更多文化內涵的資料，然而怎有好的詮釋資料的建構，亦是發展主權 AI 重要核心。以往台灣有很多有價值的文史或政府報告資料，其常見的原始留存檔案多為 PDF 檔案，而因為要符合政府開放資料的規範，公務機關會盡可能希望再將這類檔案轉成其他的可機讀格式。在這個過程中，那些因為排版需求，內嵌無法機讀圖片、混雜表格、多欄版面的設計，會造成機器解讀不易得問題。但是因為近年隨著 AI 技術成熟，光學字元辨識 (OCR) 與自動版面判讀等開源工具的進展，讓此類資料更有機會納入訓練流程。若能再進一步搭配更完善的詮釋資料建置，例如在這些類型的資料的詮釋資料中清楚標示文件結構與目錄資訊，將能進一步提升自動判讀的準確性，讓 AI 訓練或應用皆有更豐富的來源。

1.1.2 提升至「AI-Ready 資料」的意涵

在本研究中，所關注之核心在於：如何由既有開放資料出發，逐步提升至「AI-Ready 開放資料」。在此精進過程，臺灣目前參考歐盟所提出之資料治理 FAIR 原則，從資料的可發現性 (Findable)、可近用性 (Accessible)、互通性 (Interoperable) 與可重用性 (Reusable) 四個面向，並以詮釋資料 (metadata) 規範框架作為導入提升的關鍵切入點，以強化資料來源透明度與整體資料品質^[2]。美國商務部於《Generative AI and Open Data: Guidelines and Best Practices》中指出在資料發布階段即應納入 AI 系統自動擷取

與理解的需求，確保資料具備支援 AI 訓練的基礎條件 (U.S. Department of Commerce, 2025)。

而世界銀行提出之《AI-Ready Development Data》概念，其從三個關鍵條件，來導引資料邁向 AI-Ready 的發展。首先，在「AI-Ready 資料系統」方面，需建構資料探索平台、應用程式介面 (API) 及相關技術標準的基礎建設，使資料得以被有效發現、互通與存取。其次，在「高品質資料與詮釋資料」方面，資料應具備可靠性與即時性，並搭配結構化且完整之詮釋資料，以確保機器與人類皆能正確理解其內容與脈絡。最後，在「健全治理與策略性合作」方面，透過完善政策、標準化流程及跨部門協作，確保資料品質與一致性，提升透明度，並促進資料之負責任使用，以建立對資料之信任^[3]。

綜合上述原則，本研究所期待之「AI-Ready 開放資料」，係指資料於釋出階段即納入未來應用情境之考量，選擇適切之資料格式，並同步建置必要之詮釋資料，於必要時進一步提升其開放等級與結構化程度。其目標在於確保資料於人類與 AI 系統運用時，無論作為訓練資料、微調資料，或作為延伸存取與再利用之用途，皆能在準確度、完整度與信效度上具備良好之可用性與延展性，並降低資料誤用與模型偏誤之風險。

指資料於釋出階段即納入未來應用情境之考量，選擇適切之資料格式，並同步建置必要之詮釋資料，於必要時進一步提升其開放等級與結構化程度。其目標在於確保資料於人類與 AI 系統運用時，無論作為訓練資料、微調資料，或作為延伸存取與再利用之用途，皆能在準確度、完整度與信效度上具備良好之可用性與延展性，並降低資料誤用與模型偏誤之風險。

1.1.3 開放資料運用於 AI-Ready 時的注意事項

若網路資訊涉及侵權或隱私爭議，為了停止傳播，可以透過移除原始網頁或要求搜尋引擎移除索引，讓資訊隨連結失效而逐漸消逝。不過在訓練 AI 模型時，資料會被轉化為數以億計的參數權重，將資訊深度內化於其複雜的神經結構中，導致 AI 有著「無法遺忘」的特性^[4]，因此在進行資料訓練前，仍需注意訓練資料是否有違反作權或合理使用規範，及含有人隱私資料等潛在風險。

1. Berners-Lee, T. (2006). Linked data: Design issues, <http://www.w3.org/DesignIssues/LinkedData.html>. 並詳見後續的說明 <https://5stardata.info/zh-TW/>

2. Ministry of Digital Affairs. (2025). *AI-Ready data metadata framework and indicator guidelines* (1st ed.). Ministry of Digital Affairs. <https://www-api.moda.gov.tw/File/Get/moda/zh-tw/ae1g6Uvj4fUa4a3>

3. World Bank. (2025, July 21). *From open data to AI-ready data: Building the foundations for responsible AI in development*. World Bank Blogs. <https://blogs.worldbank.org/en/opendata/from-open-data-to-ai-ready-data-building-the-foundations-for-re>

4. Schlarman, Julian, and coauthors. "What Should LLMs Forget? Quantifying Personal Data in Large Language Models." arXiv, June 1, 2025, <https://arxiv.org/abs/2507.11128>.

5. Deng, Jia, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. "ImageNet: A Large-Scale Hierarchical Image Database." In 2009 IEEE Conference on Computer Vision and Pattern Recognition, 248–255. IEEE, 2009.

1.2 AI-READY 開放資料具體效益

史丹佛大學李飛飛教授團隊過去曾建立 ImageNet 開放資料集，涵蓋超過 2 萬個類別，共 1400 多萬張被標註的圖片^[5]。這個資料集改變了 AI 影像辨識的發展，圖片分類準確率在 7 年內從 71.8% 到超過 95%，更成為醫學影像、自動駕駛、臉部辨識應用的訓練基礎。^[6] 由此顯示高品質、良好標註的公開資料集能夠催化整個產業的技術突破，更能預期 AI-Ready 資料將對人類文明的發展帶來的實質幫助。

1.2.1 產業發展 創造價值

依據麥肯錫顧問公司資料，開放資料每年可在全球七大產業創造高達 5 兆美元的經濟價值。這個龐大的經濟價值源自於開放資料在 AI 訓練的運用，可見 AI-Ready 資料的巨額產業效益^[7]。

同時報告也指出，LLM 研究人員花費高達 80% 時間將政府開放資料轉換為適合 AI 訓練的格式。這反映出，若政府能直接產出 AI-Ready 資料，不只能加速國家科技發展，更能減輕該國企業高額の資料處理成本。

1.2.2 文化保存 穩固主權

當一個國家語言資料在公開的訓練集中的佔比極低，該國民眾在使用主流 AI 模型時，將無法獲取符合該國國情的資訊，將面臨「被邊緣化」與「被錯誤解讀」的問題。若長期處於這樣的使用情境，恐怕會潛移默化地影響使用者本身的認知，導致民眾及下一代對自身國家政治、歷史等領域產生認知偏差。這不僅對國家文史保存極具威脅，更對國家本身認同產生危機。

6. Blaivas, Michael, and Leslie Blaivas. "Are Convolutional Neural Networks Trained on ImageNet on Par with Humans for Point-of-Care Ultrasound Classification?" *Journal of Ultrasound in Medicine* 40, no. 6 (2021): 1099–1107.

7. Manyika, James, Michael Chui, Diana Farrell, Steve Van Kuiken, Peter Groves, and Elizabeth Almasi Doshi. "Open Data: Unlocking Innovation and Performance with Liquid Information." McKinsey & Company, October 2013, <https://www.mckinsey.com/capabilities/tech-and-ai/our-insights/open-data-unlocking-innovation-and-performance-with-liquid-information>.

第二章 世界各地 AI-READY 開放資料發展

在介紹如何將開放資料轉變為 AI-Ready Data 之前，本研究將先介紹 AI-Ready 開放資料在世界各地的實踐，以及本研究訪談數個相關專案與組織的案例，讓讀者對於 AI-Ready 資料的實際運用能有所了解。

在從傳統開放資料邁向 AI-Ready 資料的過程中，各國因制度背景與政策目標不同，逐步發展出幾種具代表性的推動路徑，可觀察到幾種相對清楚的政策趨勢與發展方向。

2.1 世界與臺灣的發展趨勢

本段先比較世界上 AI-Ready 資料發展的四種趨勢，以及台灣的路徑為何：

2.1.1 世界主要國家的發展

第一類趨勢承襲既有開放資料發展脈絡中對「規模與市場導向」的重視。以美國為代表，其以聯邦政府長期累積的大量開放資料為基礎，透過產業市場應用為核心的公私協力模式，促進資料 AI 相關產業中的應用，例如美國商務部 2025 年發布專門指引^[8]，提出讓開放資料更適合用於生成式 AI 或各式 AI 工具的步驟與標準；第二類趨勢則是「法規與制度信任優先」的發展，歐盟即為這類趨勢的代表，這一類的發展模式深信，在具備高度法律確定性與信任的環境下，AI 經濟才能永續發展。舉例來說，透過具法律約束力的指令，強制要求成員國釋出特定規格的資料的《高價值資料集實施法案》（High-Value Datasets Implementing Act）。

第三類趨勢則是以「數位主權爭取導向」，以阿拉伯語系國家為例，特別是海灣合作委員會（Gulf Cooperation Council, GCC）成員國，AI-Ready 資料政策的討論往往同時涉及國家主權、語言使用與文化保存等因素。這些國家在推動資料開放時，通常會審慎評估哪些資料適合對外釋出，哪些資料需保留在國家或特定機構掌控之下，以確保 AI 發展不致削弱在地語言與文化脈絡。

回頭檢視東亞國家與新加坡，則多是採務實混合型的路徑。以日本為例人口高齡化與勞動力短缺的結構性挑戰，其將 AI 視為支撐社會運作與公共服務的重要工具，因此在法律制度上，為資料使用與 AI 訓練提供相對彈性的空間，以加速有更多資料得以運用，加速了 AI 應用與實驗。韓國與新加坡在推動 AI-Ready 資料及開放資料的治理策略上，皆呈現由政府主導、具策略性規劃的模式，均將資料治理與 AI 發展視為國家整體競爭力的一部分，透過國家政策架構與制度設計，引導資料公開、技術實踐與產業應用。在韓國，政府透過國家級 AI 與數位平台政策（包含政府資料共享、跨部會資料整合等措施），強調提升資料流通與利用效率。

2.1.2 臺灣近期發展

臺灣自 2012 年推動政府資料開放，至 2020 年底已累積超過 4.8 萬項資料集。2020 年起，政府啟動「智慧政府 2.0」計畫，將重心由數量轉向品質，推動「高應用價值資料」的釋出，優先聚焦交通運輸、健康醫療、氣候環境等領域。數位發展部成立後，進一步推動「資料開放 2.0」，強調結構化、API 化及跨域協作，為 AI 訓練提供了穩健的數據基礎。隨著生成式 AI 興起，為避免 AI 模型產生文化偏誤，臺灣積極發展主權 AI 語料庫。國科會於 2023 年推出「可信賴人工智慧對話引擎」（TAIDE），整合政府出版品、學術論文及在地新聞，打造具備臺灣文化脈絡的繁體中文大語言模型。數位發展部於 2025 年正式推出 Beta 版語料庫，首波釋出約 6 億組詞元 (Tokens) 的高品質正體中文資料，涵蓋 200 多個機關的法律、文化、教育等領域，並建立實名制授權機制，平衡資料利用與著作權保護。

為解決臺灣語料獲取的法律障礙，政府修訂法規以加速非敏感性資料的釋出，並擬定《促進資料創新利用發展條例》。此外，民間如中華民國資訊經理人協會推動的「Taiwan Tongues」計畫，結合文學、方言（如台語）等在地語料，補足了官方資料之外的文化多樣性。

8. U.S. Department of Commerce, Generative Artificial Intelligence and Open Data: Guidelines and Best Practices, Version 1, January 16, 2025.

關懷重點

科技脈絡

關注以資料為核心的技術特性與處理能力，及其案例目前的技術實踐方式為何。

組織脈絡

分析推動單位的內部協作模式，及怎樣串連各組織間的協作。

環境脈絡

探討組織運作的外部場域，主要關注於其法律背景與其制度產生的適應。

本研究關注議題

1. 資料處理技術流程
2. 隱私與去識別化實踐技術細節
3. 其防範偏見的方法

1. 篩選組織適當與擁有的開放資料
2. 協調跨機關組織的資料取得
3. 資料管理單位的利害關係人管理
4. 跨機關協作模式（公對公、公對私）

1. 面對的法遵背景
2. 其隱私與去識別化的合規
3. 著作權與授權條款的合規

2.2 世界各國實際案例研究


除了世界上的 AI-ready 運用趨勢介紹之外，本研究也訪談世界上實務界不同的單位與專案負責團隊，讓讀者能對於 AI-ready Data 的公私協力有更具體地想像，再於之後的章節分析其經驗。

2.2.1 案例分析架構

本研究採用 Tornatzky 與 Fleischer（1990）提出的科技 - 組織 - 環境（Technology-Organization-Environment, TOE）框架作為分析工具^[9]，用以評估案例並整理訪談摘要。TOE 框架是一種廣泛應用於科技創新採用與導入的研究理論，其分 Context）及環境脈絡（Environmental Context）來思考「在怎樣的社會環境與組織協作之中，得以用怎樣的技術脈絡，釋出更多開放資料以發展 AI-Ready 的開放資料為核心」其不同面向所需的策略或方法，具體面向如本頁上圖。



9. Tornatzky, L. G., & Fleischer, M. (1990). The processes of technological innovation. Lexington,



橫軸（技術脈絡成熟度）反映不同案例在資料處理的技術能力上之差異，從高度仰賴人工處理到具有大規模自動化處理能力；**縱軸（制度與組織完備度）**則綜合了法律制度與組織協作的發展程度，從缺乏明確法規與協作架構到具有完整且制度化的治理框架（包含法規、跨部門合作與資源整合）。

2.2.2 案例挑選與定位

為了於國際案例中挑選出適合的訪談案例，本研究根據 TOE 框架三種脈絡特性，拉出兩個象限來分析，本研究嘗試先於文獻探討整理各種文本時，先將查到的案例定錨於二維坐標上，藉以確保將不同技術與制度發展的程度，及不同組織法制脈絡下，均有著可探究的案例，分析如本頁頂圖。

2.3 案例概述與重點摘要

本節將針對本報告針對這些案例所做的基礎資料整理，及進一步於訪談中獲取的研究亮點，摘要說明於下述子項目。

2.3.1 西班牙 ImpulsaDATA 計畫 案例

ImpulsaDATA 計畫由西班牙資料總局局長 Carlos Alonso Peña 親自領導^[10]，目標是陪伴西班牙公務機構走過因為必須同時遵守過多法規而陷入的資料開放困境。ImpulsaDATA 提供陪伴式的支援，協助因為不確定應該優先遵循哪些規範的各部會識別哪些資料可以安全開放。該計畫透過「診斷、缺口、行動」方法論和務實的協作機制來化解機關顧慮。

受訪者：
Co-Founder
Lukas Gienapp
Martin Potthast

2.3.2 德國 The German Commons 案例

The German Commons 專案由專案主持人 Lukas Gienapp 和 Martin Potthast 帶領。^[11]這個專案希望提供更多高品質且具備開放授權的德語訓練資料。該專案彙整了 41 個具備明確授權（如 CC-BY-SA 4.0）的資料來源，亦釋出自動化程式碼庫，涵蓋了從資料清洗、去除可資識別資料等完整流程。期能透過符合現行著作權相關規定的資料處理流程，輔助開發完全開放的德語大型語言模型。

受訪者：
Co-Founder
Lukas Gienapp
Martin Potthast

10. datos.gob.es. “Impulsadata: Nuevo Servicio de Apoyo a la Apertura de Datos de Alto Valor.” datos.gob.es, 2025, <https://datos.gob.es/es/noticias/impulsadata-nuevo-servicio-de-apoyo-la-apertura-de-datos-de-alto-valor>.

11. Gienapp, Lukas, et al. “The German Commons - 154 Billion Tokens of Openly Licensed Text for German Language Models.” arXiv:2510.13996 [cs.CL], October 15, 2025, <https://arxiv.org/abs/2510.13996>.

案例研究地理分布圖



2.3.3 柬埔寨 Open Development Cambodia 案例

柬埔寨民間組織 Open Development Cambodia (ODC) 成立超過十年。^[12] 在政府資訊公開法或個人資料保護法尚未成熟下，ODC 擅長以實質技術協助柬埔寨政府，進而展現自身價值，促使政府機關願意分享資料。透過民間發起，公民與政府所建立起來信任關係的模式成功彌補法律對於資料開放空缺，而這樣的信任關係也逐步發展為長期合作關係，進而提升政府機關的資料管理和整合能力。

受訪者：

Program and Strategy Associate	Wen-Ling (Amy) LAI
Partnership and Program Manager	Vimoil OURN
Executive Director/Editor-in-Chief	Try THY

2.3.4 德國 Parla 案例

本專案由柏林市府辦公廳（Senate Chancellery of Berlin）與德國柏林市創新實驗室（CityLAB Berlin）共同開發。此專案的核心目標在於優化柏林公共行政文件的檢索流程。目前該系統可以透過提取議會文件網站超過 11,000 份的公開檔案，並且以生成式 AI 聊天機器人的形式，自動生成回覆民眾建議。

受訪者：

Lead Prototyping at CityLAB Berlin Ingo Hinterding

2.3.5 法國 CroissantLLM 案例

法國 CroissantLLM 專案透過善用法國政府開放資料倡議平臺集中釋出的各部會資料^[13]，在這些開放授權的政府開放資料中，訓練出了一個 13 億參數（parameter）、真正雙語的開放語言模型。此專案主要利用法國政府開放資料倡議平臺所彙整的跨部會資料，開發出具備高透明度與效能的模型。

受訪者：

Co-Founder Manuel Faysse

12. Open Development Cambodia. “Home.” Open Development Cambodia, accessed December 24, 2025, <https://opendevdevelopmentcambodia.net/>.

13. Faysse, Manuel, et al. “CroissantLLM: A Truly Bilingual French-English Language Model.” arXiv:2402.00786 [cs.CL], February 1, 2024 (v1), last revised April 9, 2025 (v5), <https://arxiv.org/abs/2402.00786>.



本圖使用 Google Gemini 生成

第三章：開放資料究竟怎麼變成 AI-READY

本章將從上一章提及的案例訪談中，擷取讓開放資料變成 AI-ready 的技術實務經驗。

人們容易有個迷思，認為要將手邊的資料轉變到當前最熱門的 AI-Ready 的狀態，肯定需要額外採購昂貴的軟體，或是讓同仁加班進行繁瑣的資料清理。然而從本研究訪談的多個國際案例中，發現絕大多數情況下，只需要依循既有的開放資料流程，甚至可以比過去做得更少都有機會為 AI-Ready 貢獻一份心力。

AI-Ready 講求找回資料最原始、最樸素的樣貌，不同於過去講求民眾的易用性，無需將試算表或文件轉換成圖片或 PDF，因此不必然會增加工項只專注於釋出原始和機器可讀的格式。換言之，對於第一線工作人員，直接匯出並上傳原始檔，無需編輯或另存新檔是可行的，且是最高規格的 AI-Ready 實踐。本章的目的便是為願意直接產出 AI-Ready 開放資料的機關，指出重新規劃或簡化流程的方向。

在 TOE 分析框架下，本章聚焦於科技脈絡的綜合分析，探討各案例在推動開放資料邁向 AI-Ready 過程中，所需關鍵技術如何被具體實踐。透過案例比較，本章將進一步剖析其因應技術發展的三項核心面向，包括資料格式轉換與機器可讀性提升、隱私保護與去識別化技術的應用，以及資料偏見的辨識的方法。



3.1 使用機器可讀格式

受現代社會的閱讀習慣影響，在所有受訪案例中，PDF 文件的處理幾乎是每個團隊都必須面對的共同課題。柏林市政府創新實驗室 CityLAB 所開發的 Parla 系統，他們希望能讓超過一萬一千份的議會文件能夠被 AI 搜尋與摘要。這本該是 AI 最擅長的領域，專案負責人卻在訪談中直言，因為這些極具價值的行政紀錄全數是以 PDF 格式儲存，並非適合 LLM 處理的格式，必須先透過 OCR 軟體轉換成機器可讀的文字，讓他們遭遇了巨大的技術債（Technical debt）挑戰。

3.1.1 有系統地 OCR 轉換與文件傳承

為了讓機器讀懂這些內容，Parla 團隊不得不投入大量資源進行 OCR 轉換。然而這個將圖片轉回文字的過程中，原始文件的結構性元素，例如格式編排、段落分隔、表格標題等，都可能在轉換過程中流失，進而改變文字的脈絡意涵。因此從這個經驗指出，品質控管只能部分自動化，開發過程中的人工檢查絕對不可或缺。因此在專案啟動初期，如何處理 PDF 文件的最佳實務知識成為了研發關鍵，團隊投入了大量反覆試驗才逐漸摸索出可接受的成果。有鑒於這段學習歷程的艱辛，他們後來將經驗整理成技術文件公開分享，希望後來者不必重蹈覆轍。

3.1.2 注意不同時代字體差異造就的可讀性差異

德國語料庫計畫 German Commons 的經驗也遭遇到類似挑戰。這個計畫彙整了來自 41 個來源、涵蓋七大領域的德語文本，最終產出 1,545 億個詞元（token）的訓練語料。計畫主持人 Lukas Gienapp 在訪談中解釋，他們在資料過濾階段損失了將近一半的原始資料量，其中最主要的原因除了語言辨識過濾之外，就是 OCR 轉換所產生的錯誤。

問題的根源在於，German Commons 整合了大量歷史文獻，這些文獻通場使用古老德語字體 Frakturschrift，其外觀與現代字型差異甚大。這些歷史文獻最初被數位化時，當時的 OCR 技術尚未成熟，無法準確辨識這類古老字體，產生了大量的辨識錯誤。這些錯誤一旦存在於原始資料中，將對於語言模型的訓練將造成嚴重的負面影響，因此團隊必須選擇採取較為積極的過濾策略，也就是寧可損失資料量，也要確保整體成果品質。這樣的策略提高了資料損失率，也反映出許多政府公開紀錄即便名義上開放，在缺乏機器可讀性格式的情況下，卻無法達到開放的實質影響力。

3.1.3 配合不同資料狀態選擇適合 OCR 策略及格式

在另一方面，值得注意的是，German Commons 團隊在處理確實需要執行 OCR 的文件時，會依據資料現況，給予兩種不同的技術路徑選擇。對於已經內嵌文字層的 PDF 文件，他們使用 Grobid^[14] 這套工具來萃取文字；對於純粹是掃描影像的 PDF，則採用 Allen AI 研發的 Olmocr 模型進行辨識。這種根據文件特性選擇適當工具的策略，值得其他計畫參考。然而現實是，即便他們使用了如 Grobid 或 OlmOCR^[15] 等先進工具，在現存技術下，對於舊式字體或複雜排版的辨識率仍有極限。

綜合以上案例，對於希望讓開放資料更適合 AI 訓練的讀者，可以歸納出幾項實務建議。首先是優先釋出機器可讀格式，以最普遍的試算表資料為例，即便釋出的是 CSV 格式，假如其中包含為了人類閱讀方便而存在的合併儲存格、空行，AI 依舊無法順利理解試算表的內容。這些「人眼友善」的排版設計在 AI 訓練過程中往往會變成混亂的噪音。因此應同時釋出未經美化加工、具備一致性標頭欄位定義的原始檔。

若資料性質不需要試算表，除了傳統的純文字檔，或許也能考慮採用 Markdown 格式。這種格式能在極小的檔案體積下，精準地保留標題層級、列表結構與引用關係，讓 AI 能夠在理解內容的同時，也掌握文章的邏輯骨架。假如文章內需要連結不同段落的資訊，JSON 或 XML 等結構化格式則能提供更嚴謹的資料基礎，大幅降低後續清理的成本。

3.1.4 資料產製留存即思考機器可讀性與開放授權

此外，過往公務機關為了避免檔案在不同作業系統、軟體開啟會有跑版問題，會直覺以 PDF 檔案格式存檔，甚至將其做為釋出格式，然而各種原始的資料格式如得以一起開放釋出會是最佳的選項。舉例來說：如果原始資料是試算表，直接釋出 CSV 或 Excel 檔案；如果是文字文件，直接釋出純文字檔或結構化格式如 JSON、XML 等。其次，若因特定原因必須提供 PDF，應優先選擇內嵌文字層的 PDF，而非純粹的掃描影像。最後，如果機關內部有餘力，可以考慮提供多種格式並存，讓不同需求的使用者都能找到最適合的版本。

法國的 CroissantLLM 計畫則展示如果資料一開始都以機器可讀格式釋出，會帶來多大的便利與效益。這個計畫訓練了一個 13 億參數、真正雙語的開放語言模型，其法語訓練資料主要來自法國政府的開放資料倡議。根據團隊成員說明，法國政府透過開放資料倡議平台（data.gouv.fr）集中釋出各部會資料，這些資料均採用如 MIT License 或 Creative Commons 等寬鬆授權條款，使用者無需逐一向各機關申請授權即可直接下載使用。資料釋出時已完成格式標準化與基礎品質檢核，因此 CroissantLLM 團隊只需進行少量的資料清理工作，整體流程相當順暢。這個案例說明，當政府端建立統一的開放資料平台、採用明確的授權機制、並在釋出前完成基礎處理時，下游的 AI 開發者確實能夠大幅降低資料準備的成本。

14. GROBID. (n.d.). GROBID tools. Retrieved April 9, 2026, from <https://grobid.org/>

15. Allen Institute for AI. (n.d.). olmOCR. <https://olmocr.allenai.org2>

3.2 個資去識別化流程

個人資料保護原本就應在開放資料工作流程內，也是所有開放資料工作者都必須審慎面對的議題。當談論釋出原始資料，公務機關最擔心的莫過於隱私外洩。

3.2.1 四次內的隱私風險控制

法國的 CroissantLLM 團隊在訓練其法語雙語模型時，採取了相當務實的策略。他們優先採用法國政府開放資料平台上已具備寬鬆授權的資料集，以及法國國家圖書館中已經進入公共領域的書籍，進而免去了去識別化相關的工作。這些資料來源本身就不包含需要保護的個人資料，因此在釋出前通常已經過初步的行政審查，去除了大部分敏感個資。此外，團隊成員更在訪談中坦言，他們並沒有執行傳統意義上的去識別化處理，就是因為所使用的公開政府資料本來就不含個人可識別資訊（Personally Identifiable Information，簡稱 PII）。

但這不代表 CroissantLLM 團隊便因此掉以輕心。為了進一步確保安全，他們採取了另一種形式的隱私保護驗證，也就是在模型釋出前，針對模型記憶（model memorization）現象進行實驗。這項實驗會在訓練資料中植入特定字串，藉此觀察模型是否會重新輸出涉及個人隱私的內容，以防止人工智慧因過度學習而背誦敏感資訊。實驗結果顯示，當訓練語料中的單一資料重複次數控制在四次以內，其隱私洩漏風險則對應較低。這個實驗也再次反映大型語言模型的其中一個特性，就是「模型對訓練語料的記憶力與資料出現的頻率呈正相關」。當特定敏感資訊的出現次數極低時，模型權重則不足以支撐其精準複誦出該段內容。這項研究後來也發表於機器學習頂尖研討會 ICML，協助延伸與 LLM 的著作權陷阱相關的探討。^[16]

3.2.2 有語境脈絡地設計去敏感代碼

若要處理未經清洗的文本，German Commons 的作法同樣具有技術參考價值。該計畫整合的絕大多數資料來自歷史文獻，所包含之個人資訊早已不具時效性。計畫主持人 Lukas Gienapp 解釋，對於歷史資料而言，其中的個人可識別資訊（Personally Identifiable Information, PII）大多已經超過八十年，沒有具有保護的急迫性。

儘管如此，German Commons 仍然選擇執行 PII 移除程序，主要是考量到資料集中也包含了少量的網路來源文本。他們使用微軟的 Presidio 框架搭配針對德語優化的正規表示式（Regular Expression，簡稱 Regex），來偵測並處理電話號碼、信用卡號碼、地址、銀行帳號等可能被惡意利用的資訊。在技術實作上，團隊在 Presidio 之上增加了針對德國特定格式的正規表達式偵測，例如德國區域碼的電話號碼、德國銀行帳號的特定前綴等。

Lukas Gienapp 在訪談中分享了一項重要的技術觀察：執行 PII 移除時，不應該單純地刪除偵測到的敏感資訊，而應該以通用的替代內容取代。傳統的去識別化往往是直接刪除敏感字串，但 German Commons 團隊選擇以通用標籤替換

（Replacement）而非刪除。他舉例說明，如果只是移除所有信用卡號碼，訓練出來的模型將永遠學不會信用卡號碼的樣貌；但如果準備一組已知安全可用的通用信用卡號碼作為替代，隨機插入取代原本的敏感內容，模型仍然能夠學習到相關的語境脈絡。例如將「張君雅住在台北市」改為「[PERSON] 住在 [LOCATION]」，而非直接刪除人名與地名。這麼做的目的是為了保留句子的語法結構，讓語言模型能學習到正確的文法與上下文關係，而不至於因為個資刪除而學出破碎的語句。

此外，Lukas Gienapp 也強調這個替代過程必須具備可追溯性，German Commons 在論文附錄中詳細列出了他們選用的所有通用替代值，讓後續使用者能夠掌握資料經過哪些修改，必要時也能進行不同的替代處理。

3.2.3 弱勢文化的隱私議題

除了技術層面，ODC 的經驗則呈現了在法律框架尚發展中的環境，實務工作者如何謹慎拿捏資料釋出的分寸，同時提醒讀者需注意法律之外的文化隱私。在許多開發中國家或法律尚未完備的地區，即便某些資料依法可公開，但若涉及原住民或特定弱勢社群的居住地與身份，仍可能造成實質傷害。ODC 的工作人員在訪談中解釋，他們與政府機關建立信任關係的過程中，學會了尊重對方與溝通。例如與環境部合作時，對方表示並非所有報告都能公開，ODC 會詢問對方原因，了解對方的思維和顧慮，學著判斷對政府而言哪些報告可以對外公開、哪些只能作為研究或學習用途。同時 ODC 也會盡可能提出潛在解決方案，和政府與利害關係人對話。

更值得關注的是 ODC 對於文化敏感資料的處理態度。工作人員在訪談中分享了一個發人深省的觀察：在柬埔寨，許多原住民不願意承認自己的身份，因為他們不希望受到差別對待。即使只是提及一個名字，都可能對當地社群造成傷害。這對本研究的提醒在於，個資保護不僅僅是技術層面的去識別化處理，更需要對在地文化脈絡有深刻的理解。ODC 在處理這些資料時，會引入比法律更嚴格的社群準則，在資料釋出前確保不會對弱勢族群造成二次傷害，這種以人為本的思維，不能僅依賴自動化工具與法規底線，更需具備對在地脈絡的文化敏感度，值得所有開放資料工作者借鏡。

3.2.4 小結

從這些案例中，可以整理出幾項實務原則。首先是源頭管理優於事後處理，如果能在一開始就選擇本質上不含敏感個資的資料類型進行開放，後續的去識別化工作量將大幅降低。其次，當確實需要執行去識別化時，應採用替代而非刪除的策略，以保持文本的完整性與可用性。最後，去識別化的處理過程應該透明且可追溯，讓後續使用者能夠理解資料經過哪些處理，並在必要時進行調整。

16. Meeus, Matthieu, Igor Shilov, Manuel Faysse, and Yves-Alexandre de Montjoye. "Copyright Traps for Large Language Models." In Proceedings of the 41st International Conference on Machine Learning (ICML 2024), 2024. <https://dl.acm.org/doi/10.5555/3692070.3693506>.

3.3 消除訓練資料偏見

訓練資料的偏見問題，是所有語言模型開發者都必須面對的課題。資料的品質決定了 AI 的視野，若餵給模型的資料存在偏差，模型輸出的觀點自然也會偏頗。從各個團隊訪談的案例中，本研究團隊觀察到偏見可能以多種形式存在，而不同團隊也發展出各自的應對策略。

3.3.1 有意識地設計語料比例與釋出開放工具

CroissantLLM 計畫的核心目標之一，是打造一個真正具備雙語能力的語言模型。這個目標的背景是，當時坊間聲稱支援法語的模型，往往仍以英語訓練資料為主，僅在其中摻入少量法語內容，導致模型在法語相關任務上的表現明顯落後於英語。為了解決這種不平衡的問題，CroissantLLM 計畫在建置之初即高度重視語言的主體性，並刻意將語言比例視為一項需要人為介入與設計的重點。在訓練資料配置上，有意識地規劃以英文 40%、法文 40% 作為核心比例，並搭配約 20% 的程式碼資料，形成自然語言與結構性資料並行的混合語料。如此配置下，一方面得以避免模型能力向單一語言傾斜；另一方面，亦有助於強化模型在語言推理與模式辨識上的穩定性。

除了模型本身，CroissantLLM 團隊也同步釋出了高品質的法語資料集，並建立專門的法語評測基準 FrenchBench。這使後續研究者與模型訓練者得以更系統性地檢視模型是否仍存在過度偏向英語的情況，並在多樣化任務中實際驗證法語能力是否在訓練過程中被犧牲。這也確保未來延續發展之行政、法律等高度在地化的知識脈絡，能夠被模型正確理解與生成，而非被迫經由英語思維轉譯後再回應法國的制度與政策問題。

這個經驗對於其他非主流語言的開放資料工作者具有重要的啟示意義。許多語言在網路世界中的資料本就相對稀缺，若僅被動彙整既有資源，往往只會複製甚至放大既存的語言不平衡。CroissantLLM 的實踐清楚說明，語言平衡並非自然生成，是需要刻意策劃其組成，並同時建立與釋出可供後續研究與評估參考的資料集與評測工具，才能讓非主流語言在 AI 時代各種大型語言模型中逐步站得住腳，並同時具備長期發展與被持續驗證的可能性。

3.3.2 意識到時間維度造成的偏見

German Commons 計畫則面對了另一種形式的偏見，也就是時間維度上的不平衡。該團隊觀察到一種有趣的懷舊偏見（nostalgia bias）。由於德國著作權法規定，作品在原作者過世一定年限後才會進入公共領域，因此大量可以自由使用的文化作品與報紙文獻都是歷史性的。這造成了計畫主持人 Lukas Gienapp 所稱的懷舊偏見，也就是訓練資料中充斥著數十年甚至上百年的文本，而缺乏介於非常近期與非常久遠之間的中間時期內容。這導致訓練出來的模型在語氣和用詞上可能顯得過時，彷彿活在二十世紀初。

Lukas Gienapp 坦承這個問題在現有的法律框架下難以完全解決，因為較新的文化作品仍受著作權保護。為了彌補這個現代資料的斷層，他們的應對方式是透過整合不同領域的資料來源來達成某種程度的平衡。必須積極尋找法律判決書、政府公報等當代且著作權開放的文本來平衡時間軸上的偏差。網路來源的文本自然會偏向近期內容，科學文獻由於開放取用運動興起較晚，也會呈現近期偏向，而歷史文獻則填補了更久遠的時期。雖然無法做到完美的時間分布，但至少確保了資料集不會只侷限於單一時期。

3.3.3 多語系的多樣性支援

柬埔寨 ODC 的經驗則突顯了語言多樣性處理的複雜性。同樣的挑戰也發生在柬埔寨，工作人員在訪談中指出，柬埔寨並非僅使用高棉語，同時仍有包含墨儂族（Bunong）布婁族（Brao）、歸族（Kuoy）、佬族（Lao）、嘉萊族（Jarai）、客隆族（Kreung）、卡維特族（Kavet）、坦普安族（Tampuan）和卡秋族（Kachok）等少數民族生活在不同省份，並且使用不同的原住民族語言。然後現在柬埔寨的語料庫資料多從高棉語出發，且集中在城市觀點，未來鄉村與原住民族的聲音可能會在數位世界中消失。考量現實環境無法快速產出大量原住民族語言資料，ODC 的應對策略是引入第三方語言 - 英語，藉由外援的方式盡可能先保留鄉村觀點和原住民文化。雖然以英語來平衡高棉語，進而避免國家內部訓練資料偏見的做法難免引來微詞，但非柬埔寨裔的工作人員以自身經驗為例說明，由於她不諳原住民族語和高棉語，在擔任研究實習生期間，他仍能大量仰賴 ODC 提供的英語版資料集，協助訓練 AI 多元的柬埔寨觀點。

這案例中也幫助本研究，也回扣到臺灣公務機關的角色，當民間企業傾向蒐集具商業價值的資料時，政府更有責任釋出那些看似冷門、卻具備高度公共價值的資料，例如地方誌、方言紀錄或是偏鄉的基礎建設資料。這些資料或許無利可圖，但對於修正 AI 模型的文化偏見、建構具備臺灣主體性的數位大腦而言，卻是不可或缺的關鍵拼圖。

3.3.4 透過流程設計減少偏見

從消除偏見的角度來看，這些案例也指向一個共同的解決路徑：偏見的存在往往是系統性的，因此應對策略也必須是系統性的。German Commons 的 Lukas Gienapp 建議採取兩階段的工作模式，第一階段由領域專業知識的人員先行，第二階段再讓資訊整合者（Aggregator）介入調整。具體而言是先讓具有領域專業知識的人員，先行整理各自領域的專業資料集，然後再由具備開發語料資源、系統架構規劃能力、資料處理能力的整合者，以技術再來將這些資料集彙整起來。

這種分工方式的好處在於，領域專家更能夠理解該領域資料的特性與潛在偏見，而整合者則可以從跨領域的視角來平衡不同來源的比重。

3.3.5 小結

這些經驗提供了幾項可以立即採行的做法。首先是在規劃資料釋出時，應該有意識地檢視資料的代表性，思考哪些群體或時期可能被遺漏，並在可能的範圍內補充。其次，當機關內部具備多語能力時，應考慮提供多語版本，即使只是先提供主要內容的摘要翻譯，都能大幅提升資料的可及性。最後，若機關所轄領域具有特殊的專業知識門檻，應考慮提供適當的詮釋資料或說明文件，幫助後續使用者正確理解資料的脈絡與限制。

值得強調的是，消除偏見並不意味著追求不可能達成的完美中立。每一份資料集都必然反映了其產製過程中的各種選擇與限制。重要的是對這些偏見保持警覺，在可能的範圍內加以緩解，並且誠實地向使用者揭露已知的限制。German Commons 的做法就是一個好的示範，他們在論文中詳細分析了資料集的時間分布與領域組成，讓使用者能夠根據自身需求判斷這份資料是否適用。



本圖使用 Google Gemini 生成

第四章：推動 AI-READY DATA 需要哪些環境、政策與調適行動

本章旨在透過 TOE 分析框架，分析本研究所蒐集之案例，說明在何種制度、組織與環境脈絡下，得以促使開放資料逐步邁向 AI 整合運用。透過不同國家與案例的交叉比較，本研究團隊希望呈現並非僅有「具備最佳條件的環境」方能推動 AI-Ready 資料，而是各種不同治理情境中，皆可能發展出相對適切的推動模式。本章亦進一步探討，各案例如何在既有治理限制、法規規範與政策支持條件下，透過制度設計與組織協作等實務調整，推動 AI-Ready 資料相關作法。

4.1 法律框架與其社會制度發展

本節聚焦於 TOE 分析框架中的環境脈絡（Environmental Context），探討法律制度與社會治理結構如何形塑開放資料邁向 AI-Ready 的發展條件。環境脈絡關注的不僅是單純法規或制度的存在與否，而是更廣泛的社會脈絡，包括資料法制觀念的完備程度、普羅大眾對於隱私與個資保護的認識和要求、著作權與授權制度執行的落實情形，以及社會對資料使用與 AI 發展的信任基礎等。在本節中透過案例分析，說明不同法律框架與社會制度如何影響資料釋出的可行性、組織的行動空間，以及 AI-Ready 開放資料在實務上的推動方式。

4.1.1 清晰的開放資料法律框架

4.1.1.1 支持政府資訊公開的政策或具體立法

CroissantLLM 和 Parla 在資料取得的過程，清楚展現了完善的開放資料法律框架能降低開發者溝通成本並提升開發效率，為 AI 研究鋪平道路。CroissantLLM 團隊的研究者 Manuel Fayssie 受訪時指出，法國政府推行的開放資料倡議讓資料取得過程變得極為單純，由於政府已釋出大量具備寬鬆授權條款的資料，團隊成員直言資料授權「對我們來說並不困難，模型開發過程只需對這些開放資料集進行少量的清理工作」。Parla 的產品負責人 Ingo Hinterding 則強調，「只要研究團隊處理的是無需特殊保護的公開資料，開發進程將會顯著加速」，有些國家會要求想取得政府資料的民眾做出由機關開立書面授權的要求，但在實務上，民眾不一定能夠找到正確的授權機關，因此無法取得資料。在少數情況下，開發者即便取得機關的口頭許可，但這樣的口頭約定所帶來的不確定性，反而帶來無形的壓力。

4.1.1.2 正確選擇適切的條款

國家的政策或法律架構固然重要，但實務上更關鍵的基礎在於如何為資料集標示「對」的授權條款。每一種授權條款對於資料利用的規範與限制都不同，這些差異會直接影響資料後續被轉化為訓練語料的可能性。常見的授權條款內容包括資料是否可以用於商業目的、是否可以進行修改或衍生利用或是否需要標註出處等。經過長期演進，目前國際間也有標準化的授權條款，例如創用 CC 授權 (Creative Commons)、開放政府資料授權條款等，政府需要對於公民社會或企業的需求充分考量，選擇能對大眾帶來最大利益的授權。

法國 CroissantLLM 案例中可以觀察到，法國政府在釋出開放資料時，已經預先為平台上的資料集的授權條款完成了標註作業。這讓研發團隊能夠迅速在龐雜的政府開放資料平台中，透過授權條款的差異，精確篩選出符合模型訓練需求的資料集，大幅降低了研究團隊法律風險。

4.1.1.3 簡明連貫的法規架構

在前面兩個小節，本研究談論到授權條款和支持性政策與立法的重要性，現在我們則要到更大面向的法規架構。公務機關在推動政策或立法時，如果沒有注意到明確不同法案間的競合關係，反而會讓公務人員在執行時無所適從。

例如西班牙的公共機構必須同時遵守「公部門資訊再利用指令」(The Directive on the re-use of public sector information, PSI Directive)、《一般資料保護規則》(General Data Protection Regulation, GDPR)、《資料治理法》(Data Governance Act, DGA)、《歐洲資料法》(European Data Act) 以及新興的 AI 法 (AI Act) 等多個框架，在沒有明確優先層級的情況下，「義大利麵碗式的法遵困境」(Spaghetti Bowl of Compliance) 便產生了。機關對於法規的困惑與恐懼，使他們拒絕資料開放。

歐盟執委會為了解決這個問題，開始了「立法整合」(Legislative Consolidation) 計畫。歐盟將來渴望透過統一各項法規中的定義（例如釐清在 GDPR 下「合法利益」¹⁷如何適用於 AI 訓練）、以及簡化報告義務（推行「報告一次」原則），減低開放資料推動的障礙。

4.1.1.4 小結

以上分析案例證明，當開放資料制度與開放授權條款進行整合，且有清楚且連貫的立法，研究團隊能將重心回歸 AI 技術開發，不需耗費額外資源於繁瑣的授權申請程序。明確且一致的開放授權資料集往往比規模龐大卻授權條款不清晰的資料集更具價值。

相對而言，在西班牙遭遇的法規重疊挑戰中則提醒本研究，缺乏整合的法律環境將使行政機關因對風險的恐懼而陷入停滯。

4.1.2 展現開放資料價值促進實質合作

柬埔寨至今尚未通過政府資訊公開法或類似的法律，賦予公民請求政府資訊的法定權利。個人資料保護法方面，該國草案雖然已經討論了近十年，然礙於多方利益的折衝與協調，立法進程相當緩慢。倒是 AI 方面，該國已經發布了國家 AI 策略草案，更識別出教育、農業、製造業等領域為優先發展項目。但這些策略文件實際上仍處於早期階段，尚未轉化為具體的法規或實施細則。雖然如此，公民社會組織 ODC 在這樣的環境中嘗試做出突破的行動，依然有以下的經驗值得學習。

4.1.2.1 政府需求導向的關係建立

ODC 在這樣的環境中，採取的是一種「軟性倡議」的策略。他們根據不同政府機關的文化和需求，提供實質協助、建立信任和展現價值，使政府機關有意願分享資料並調整做法。在資料分享是基於自願而非強制的情況下，柬埔寨政府機關反而更願意保持開放的態度，不會將資料申請視為對其權威的挑戰。

以 ODC 推動的經濟性土地特許權 (Economic Land Concessions) 資料公開為例，ODC 透過彙整土地管理部門、環境部門以及地方政府的分散資料，建立了一個完整的經濟性土地特許權地圖。這項工作讓柬埔寨相關機關能夠明確釐清每一塊特許區的範圍，確認和環境保護區等的界線，也避免不同土地利用之間的重疊和衝突。ODC 的初衷並非單純為了取得機敏資料，而是透過技術協助將分散在各部門的原始資訊進行整合與視覺化。在這一連串的協調過程中，政府發現這種跨部門的資料整合能有效減少施政錯誤並滿足決策需求時，原本被視為機敏封閉的土地資訊便有了開放的基礎。這種從民間需求出發，進而達成跨機關資訊流通的模式，不僅解決了眼前的問題，也讓這些經過清理與結構化的空間資訊，有機會成為後續開發土地預測或資源規劃 AI 模型時最珍貴的在地語料。

4.1.2.2 正向公私協力案例促進立法

更令人欣喜的是，成功的公私協力也能促成立法，進而補足國家法律框架的不足。

延續柬埔寨經濟性土地特許權資料公開的案例，他們的影響力有更多元的層面。該國土地特許區時常發生侵入原住民社區的案例，進而引發紛爭。藉由公開資料，原住民首次能夠以地圖空間視覺化的方式了解自己的土地權益受到哪些威脅，這些資訊成為他們向政府倡議、要求保護傳統領域的重要依據。對政府決策者而言，這個地圖空間視覺化工具揭示了土地管理政策的盲點，促使相關部門開始思考如何在經濟發展和社區權益之間取得更好的平衡。對國際投資者和民間組織而言，這些公開透明的資料讓他們能夠更負責任地評估投資計畫的社會環境影響。這些自下而上的實踐經驗都為未來的立法提供寶貴的參考。

4.1.2.3 小結

當政策制定者意識到開放資料能夠帶來的具體好處，以及實務上可行的作業模式時，他們會更有信心推動相關的法律改革。ODC 在訪談中提到，柬埔寨政府已經意識到各機關使用不同資料結構所帶來的問題，並開始討論建立統一的資料治理架構。而 ODC 在實務上累積的經驗，包括如何設計易於使用的資料格式、如何處理資料品質問題、以及如何在開放與保護之間取得平衡，都成為了政策制定者的重要參考。

17. Under the GDPR, “legitimate interest” permits personal-data processing when it is necessary for the legitimate interests pursued by the controller or a third party, provided those interests are not overridden by the data subject’s interests or fundamental rights and freedoms—particularly where the data subject is a child.

4.2 協作模式比較分析

本節聚焦於 TOE 分析框架中組織脈絡（Organizational Context），探討跨組織與跨機關協作在開放資料與 AI-Ready 推動過程中所面臨的實務挑戰。組織脈絡關注的是不同參與單位在組織文化、權責分工、資源配置與決策流程上的差異，這些因素往往直接影響資料是否得以順利釋出與再利用。

在實務上，不同政府機關因業務目標、風險承擔程度與對資料開放的理解不一，可能對開放資料採取不同的態度與執行方式；同時，當民間或學術單位參與資料推動時，組織文化與工作節奏的差異，也可能影響溝通效率與協作成果。因此，如何建立清楚的協作機制與角色分工，成為推動開放資料與 AI-Ready 資料過程中的關鍵課題。

4.2.1 建立政府內部跨機關的制度化協作

柏林 Parla 專案建立了一套橫跨行政與立法部門的長期合作架構，而非僅止於單純的採購關係。行政機關藉由柏林參議院常態性的創新補助金委託 CityLAB 運作，賦予了 CityLAB 扮演「資訊技術和行政機關的橋樑」，讓這個創新實驗室得以跨越部會藩籬，介接議會紀錄與參議院各局處的業務資料。這種補助機制本質上是一種「協作基礎建設」的投資。

西班牙的 ImpulsaDATA 計畫則展現了另一種透過制度化來達成政府內跨機關協作的模式。西班牙政府設立「資料總局」作為行政中樞，透過法定的國家資料架構與年度報告機制，將機關間的單純的諮詢業務提升為法律義務，在 ImpulsaDATA 的架構中，資料總局並非僅提供諮詢，而是透過診斷、缺口分析到具體行動的標準化流程，將複雜的歐盟法規轉譯為機關可執行的方案。

4.2.2 輔以下而上模式整合需求

案例介紹時提過，CityLAB 透過「AI Ideas Workshop」工作坊，並邀請柏林行政機關員工參與，共同討論「日常工作中哪些任務可以透過 AI 來支援？」，在工作坊中參與者表示，收取和回復議會書面質詢是一項耗時且佔用大量資源的任務。CityLAB 因此直接回應這個無需額外說服行政機關接受的痛點和具體需求。這種從概念階段就與實際使用者需求緊密結合的開發模式，確保了專案的實用性。柬埔寨的 ODC 在這方面也不謀而合。

ODC 對有意願合作的政府機關提供技術支援和訓練，以互惠的形式協助機關提升資料管理能力。這種實質的技術協助讓機關感受到合作的好處，進而更願意在資料公開上採取積極態度。例如郵電部和環境部相對開放，願意邀請 ODC 參與政策草案的討論，並在某些條件下分享資料；規劃部也接受組織提供的技術培訓和支援。兩個組織都展現了，理解實務需求與跨領域對話的能力在技術開發能力之外的重要性。

4.2.3. 資料主題性選擇

4.2.3.1 注意該資料主題的複雜性

一般來說，不同資料主題意味著組織需要面對資料本身不同程度的複雜性。在討論資料選擇策略之前，The German Commons 的經驗為本研究提供了一個重要的對照：面對巨量的潛在資料來源，系統性的主題選擇和策略性的取捨仍然是必要的；而在決定選擇那些資料來源之前，也需要對世界上存在的資料來源先廣泛了解，才能在之中選擇最具代表性的資料集。

The German Commons 團隊從一開始就設定了明確的資料領域範圍：法律、科學、文化、政治、新聞、經濟和網路文本七大領域，最終從 41 個來源蒐集了 1545.6 億個詞元。這個看似龐大的數字，實際上是經過審慎篩選的結果。團隊明確表示，他們的策略是在每個領域中選擇「最大且最具代表性的單一資料來源」，而非試圖納入所有可得的資料集。但在一開始能先了解世界上現存的資料來源有哪些，也一樣重要。以文化領域為例，雖然德語是德國的主要語言，但高品質的德語內容並不只存在於德國境內，瑞士與奧地利的國家圖書館同樣擁有豐富且具備開放授權的德語資料。然而，由於團隊在專案後期才將視角擴大到這些跨國來源，導致必須重啟部分資料處理流程。這項經驗說明，推動者在起步階段就應該具備語言的跨國視角，跳脫邊界，優先盤點全球範圍內所有可能承載該語言資料的機構。這種先求全貌再行篩選的規劃方式，不僅能確保資料涵蓋範圍的完整性，也能有效避免因後期補齊資料而產生的重複開發成本。

4.2.3.2 強調資料應用，降低政府機關對該主題資料開放的擔憂

雖然都是使用政府的開放資料來產出可供 AI 訓練的資料，而且都很注重資料的主題選擇，但 The German Commons 與 ODC 的目的性全然不同。前者主題的篩選策略是基於保障資料品質的觀點而出發，ODC 則是從如何能更容易取得政府資料的觀點出發，特別是當開放資料涉及財政收入、礦業權益、土地利益等領域時。

ODC 在訪談中提及，稅收、礦產開採等領域的資料，由於牽涉到複雜的利益關係，機關會更加謹慎甚至保守，面對資料申請時更容易互相推託責任。經濟財政部和礦業部在面對礦業收入資料的申請時，就出現了互相推諉的情況：礦業部表示他們沒有資料，應該向經濟財政部查詢；經濟財政部則回應他們只有總額，沒有各公司的細項資料。這種「踢皮球」的現象，反映了當資料涉及敏感的商业利益或政府收入時，機關往往會選擇最保守的立場。

面對這種情況，ODC 發展出了策略性的漸進式方法：對於較為保守的機關，組織不會強行施壓，而是先在環境資料、通訊政策、發展規劃等相對不涉及直接經濟利益或政治敏感性的領域建立信任基礎，等待適當的時機再提出資料申請。與環境部建立的合作關係就是一個成功的例子。起初環境部對 ODC 的資料申請也相當謹慎，但隨著時間推移，當他們了解 ODC 發布的資料都是經過負責處理的，而且確實對公共利益有所貢獻時，環境部開始願意在某些條件下分享環境影響評估報告。雖然不是所有報告都能公開，但至少建立了一個可以對話和協商的管道。

這種差異反映了一個重要的現實：資料主題性的敏感程度和機關的開放意願密切相關，推動策略需要因地制宜。從 The German Commons 的經驗中，本研究發現，即使在法律環境相對友善、資料授權相對明確的情況下，仍然需要做出策略性的主題選擇和資料取舍，以確保最終資料集的品質和實用性。而 ODC 的經驗則提醒本研究，在法律環境正發展中的情況下，資料主題的選擇不僅是技術問題，更是建立信任和推動協作的策略考量。從較不敏感的領域開始，逐步建立成功案例，往往是開啟更多資料來源的有效路徑。

4.2.4 小結

順暢的協作是開放資料與 AI 應用成功的重要基礎。無論是政府內部的跨機關協調，還是政府與民間組織之間的公私協力，都需要建立在相互信任和共同目標的基礎上。從這些案例中，本研究可觀察到幾個協作成功的共同要素：

首先，技術能力固然重要，但理解實務需求並進行有效溝通的能力同樣不可或缺。Parla 透過工作坊直接回應公務員的痛點，ODC 透過技術支援讓機關感受到合作的價值，這些做法都展現了同理心和實用主義的重要性。

其次，採取由下而上、需求導向的工作方法，能夠讓協作更容易開展。當資料使用者或技術開發者不是以「要求」的姿態，而是以「協助解決問題」的角度來與機關對話時，後者的防衛心態會大幅降低。這種工作方法也確保了最終產出的實用性，因為它們是針對真實需求而設計的。

第三，根據不同的制度環境與資料敏感度，靈活調整協作策略至關重要。The German Commons 展現了在資料豐富的环境中如何做出策略性選擇，ODC 則示範了在資源和法律都受限的情況下，如何透過漸進式的信任建立來開拓空間。沒有一種方法可以適用於所有情境，但原則是一致的：理解環境、理解限制、展現價值、建立信任。

最後，無論是透過制度化方式系統性設計協作機制，或是基於個別組織與政府機關、跨組織關係所形成的彈性協作模式，皆有助於促成具體且可觀察的實質成果。前者提供了穩定性和可預測性，後者則展現了彈性和適應力。更重要的是，這兩種路徑並非互斥，而是可以相互補充。當民間組織透過個別協作累積了成功經驗，這些經驗可以為制度化機制的建立提供參考；而當政府建立了制度化的協作框架，也能讓民間組織的工作更加順暢。對於正在考慮推動開放資料與 AI 結合的政府機關而言，這些經驗傳遞的訊息是：協作是成功的必要條件，無論是公部門內的跨機關協作，或跨利害關係人的公私協力都是。真誠地理解彼此的需求和限制，並在此基礎上找到共同的價值和目標。當這種相互理解和信任建立起來後，資料的流通、技術的應用、以及最終的社會效益，都會自然而然地隨之而來。





本圖使用 Google Gemini 生成

第五章 總結與 AI 開放資料推動藍圖

本章內容來自五個案例在實際操作中累積的具體經驗，依序說明格式轉換的技術選擇、個資去識別化的實作方法、訓練資料偏見的辨識與處理，以及長期資料管理的基礎建設規劃。每個主題都會呈現案例中採用的工具、遭遇的限制，以及最終選擇特定做法的考量因素，聚焦在第一線工作者能夠實際應用的步驟。有些機關或團隊，基於專業職責或服務品質的考量，希望在資料處理上投入更多心力。這一章便是為這些讀者準備的指引。

5.1 推動模組與藍圖

推動政府資料邁向 AI-Ready 並非一條單向前進的直線，而是一系列根據機關需求隨時調用的行動模組，在實務運作中，一個機關往往會同時面臨多個面向的挑戰，例如在具備優良硬體基建的同時，卻可能對授權條款感到困惑，或是在建立協作關係的過程中，發現既有的資料格式難以被 AI 直接利用，不同機關之間的發展速度也可能大不相同，有些部門可能因為業務性質或組織文化而更容易推動，有些則需要更長的時間建立信任。因此，本研究將國際案例的成功經驗拆解為四個行動模組，機關可以根據自身當下遭遇的問題，靈活組合這些實務建議，而非強求循序漸進。

這張表格想幫助讀者快速定位自己所處的情境，並找到相應的參考案例。重要的是理解，每個案例都在自己的限制條件下找到了可行的解方，而這些解方之間並不互斥，而是可以相互借鑑、靈活組合。

邁向 AI-Ready 資料的挑戰因應路徑圖

建立協作關係

核心任務	辨識需求並找到願意合作的機關	提供技術培訓建立能力	展現技術協助的價值
可實際操作的模組	- 從較不敏感的領域切入，例如環境資料或通訊政策。 - 透過工作坊直接詢問公務員遇到什麼困難，針對具體痛點提供解決方案。選擇本身就在尋找協助的單位作為第一個合作對象，而非最有影響力的機關。	- 與在地教育機構合作，為公務員開設資料識讀課程。 - 培訓內容應包括資料蒐集工具使用方法、資料組織原則、資料品質管理等實用技能。強調這些技能如何改善日常業務效率，而非只談開放資料的理念。	- 實際協助機關解決資料管理問題，例如協助數位化紙本記錄、建立資料目錄、設計資料蒐集表單。 - 讓機關感受到合作夥伴不是來找麻煩，而是真正能夠減輕工作負擔。
參考案例	- 柬埔寨 ODC 從環境部開始，協助整理分散的環境影響評估報告。 - 德國柏林 CityLAB 透過工作坊發現議會質詢研究是公務員的痛點，開發 Parla 系統回應需求。	- ODC 與柬埔寨數位科技學院合作，訓練規劃部同仁使用資料蒐集工具。 - 西班牙 ImpulsaDATA 對各部會提供資料治理培訓，協助機關理解良好的內部資料管理如何提升工作效率。	- ODC 協助環境部數位化環境影響評估報告，讓分散的文件能被有效管理。 - 過程中建立的信任關係，使環境部後來願意在條件允許下分享更多資料。
預期成果	建立至少一個成功案例，讓其他機關看見合作的實質價值。	公務員具備基礎資料管理能力，理解資料標準化與文件化的重要性。	機關從評估轉為開放，願意討論更多合作可能性。

釐清授權條款

核心任務	採用國際標準授權條款	參考同領域國際做法	建立授權決策流程
可實際操作的模組	- 使用創用 CC 授權 (Creative Commons) 作為主要框架。 - CC0 適用於希望完全開放的資料，CC BY 要求使用者標註出處，CC BY-SA 要求衍生作品採用相同授權。 - 選擇一個清楚的授權條款，讓使用者不需要聘請律師就能判斷資料是否適用於他們的需求。	- 科學資料常用 CC BY 4.0，政府統計資料可直接採用 CC0。 - 重點不在於選擇最寬鬆的授權，而是選擇一個明確且被廣泛理解的條款。	- 制定內部指引，說明不同類型資料適用哪種授權條款。 - 當機關內部對授權仍有疑慮時，可以先從最保守的選項開始，隨著信心增加再逐步放寬。 - 記錄每次授權決策的考量因素，累積經驗。
參考案例	- 法國政府開放資料倡議平台大量採用創用 CC 授權，讓 CroissantLLM 團隊能迅速確認哪些資料可用於 AI 訓練。 - 德國 German Commons 堅持只使用至少 CC BY-SA 4.0 或等同層級的授權，確保訓練出的模型不會面臨著作權爭議。	- 各國政府開放資料平台的授權實務。 - 臺灣政府資料開放平台也提供政府資料開放授權條款作為選項。	西班牙 ImpulsaDATA 協助各機關進行診斷，釐清哪些資料可以安全開放、應採用何種授權條件。
預期成果	資料使用者能快速判斷資料是否符合需求，機關不需要逐案處理授權詢問。	建立可預期的授權環境，降低使用者的法律風險顧慮。	機關內部對授權條款的選擇有明確依據，減少決策時間。

建立資料流通機制

核心任務	建立集中式資料平台	將開放資料納入常規流程	協調相關法規適用	提供陪伴式支援
可實際操作的模組	- 建立單一入口讓使用者能集中取得各機關資料，每筆資料都標註清楚的授權條款和詮釋資料（metadata）。 - 平台應完成基礎格式標準化，讓使用者不需要處理各機關不同的資料格式。	- 當機關完成一份報告或統計調查時，同步將適合公開的部分上傳到平台，而非等到有人申請才開始處理。 - 這種前置作業的思維，把開放資料從額外工作轉變為工作流程的一部分。	- 檢視政府資訊公開法、個人資料保護法、著作權法等相關法規如何交互作用。 - 釐清不同法律之間的優先順序，在必要時進行法規調適，讓這些法律能夠相互支持。 - 建立跨部會協調機制，討論法規適用的具體案例。	- 即使在系統化階段，仍需要深入各機關了解實際狀況，提供量身打造的行動方案。 - 透過診斷和缺口分析來發現每個單位的限制，而非用由上而下的方式強制要求配合。
參考案例	法國開放資料倡議平台 (data.gouv.fr) 集中了各部會釋出的資料，CroissantLLM 團隊可以直接從單一入口下載所需資料，無需逐一向各機關申請授權。	法國各部會在完成業務時同步處理資料開放，而非事後才進行。臺灣部分機關也已經將定期更新開放資料列為業務項目。	- 柬埔寨正在討論建立統一的資料治理框架，目標是讓各機關在組織資料時能遵循一致的結構標準。 - 臺灣在推動開放資料時也需要釐清不同法規的適用範圍。	- 西班牙 ImpulsaDATA 採用診斷、缺口、行動的方法論，協助各機關識別哪些資料可以安全開放。 - 這種陪伴式的系統化推動，比單純發布統一標準更能獲得機關支持。
預期成果	大幅降低資料使用者的取得成本，提高資料被利用的機會。	資料能夠持續且穩定地流入平台，而非依賴個別承辦人的主動性。	機關對於法規適用有明確理解，減少因法律不確定性而不敢開放資料的情況。	系統化推動不會因為忽視個別差異而造成反彈，各機關能在自己的步調上前進。

追求最完美的資料品質：建置技術基礎建設

核心任務	建立多層次儲存策略	善用既有公共基礎建設	發展或採用資料處理工具	建立品質監控機制
可實際操作的模組	- 經常被存取的資料保持在高速存取環境，較少使用但仍需保存的資料移至成本較低的長期儲存設施。 - 同時採用多重備份，例如自有伺服器搭配公開儲存平台。	- 不需要每個機關都建置大規模儲存設備。善用國家級的科學計算中心、學術網路資源、或國際組織/企業提供的長期儲存服務。 - 關鍵是建立明確的資料管理政策，知道什麼資料應該放在哪裡。	- 根據組織的技術能力和資源，選擇開發客製化工具或採用現成框架。如果採用現成工具，要確認它與現有基礎建設的相容性。 - 如果開發客製工具，應該考慮開源釋出，讓其他組織受益。	- 制定資料品質標準，包括完整性、正確性、時效性等面向。 - 建立定期檢核流程，而非只在釋出時檢查一次。記錄使用者的回饋，作為改善資料品質的依據。
參考案例	德國 German Commons 自行維護 12 PB 儲存空間的叢集運算設備，同時將資料備份到歐洲核子研究組織的 Zenodo 平台和 Hugging Face 平台。	歐洲核子研究組織的 Zenodo 平台提供每個使用者 50 GB 免費空間，適合中小型資料集的長期典藏。臺灣各研究機構可以利用國網中心的資源。	- German Commons 開發自己的資料處理流程，雖然增加工作量但能完全掌握細節。他們後來將經驗整理成開源工具分享。 - 法國 CroissantLLM 則善用既有的開源工具進行資料清理。	德國柏林 Parla 在處理 OCR 轉換時，必須進行大量人工檢查確保品質。他們將經驗整理成技術文件公開分享，讓後來者不必重蹈覆轍。
預期成果	確保資料不會因為單一平台問題而完全失去可及性，同時控制儲存成本。	在有限預算下仍能確保資料的長期保存與可及性。	建立符合自身需求的處理能力，累積的經驗能夠回饋給社群。	持續提升資料品質，建立使用者對資料的信任。

並不用每一步都照著走

更重要的是，這些解方之間存在著相互依存的關係。協作中建立的信任關係，會成為後續系統化推動的基礎。遇到阻力時發展的陪伴機制，能夠幫助更多機關跨過門檻。追求卓越品質時累積的技術經驗，可以回饋給推動者作為參考。這種彈性且穩健的發展方向，往往比嚴格遵循某個既定路線圖更能應付實際環境的複雜程度。

5.2 AI-Ready 資料賦能民主與社會

當談論開放資料邁向 AI 整合運用時，容易陷入純粹技術的討論，忽略了更根本的問題，「這一切為了什麼？」從這次研究的案例中，本研究發現了三個面向的賦能可能性，它們共同構成了開放資料在當代社會的價值基礎。

5.2.1 賦能公務員自身的工作

開放資料推動工作最直接的受益者，最終是公務員自己。Parla 專案的經驗清楚展現了這一點。當柏林行政機關的員工在工作坊中表達研究議會質詢是一項耗時的任務時，CityLAB 開發的解決方案不僅幫助他們節省時間，更重要的是讓他們能夠更有效地回應民意代表的質詢，提升工作品質。

西班牙的 ImpulsaDATA 計畫同樣體現了這個價值。西班牙資料總局局長 Carlos Alonso Peña 在訪談中提到，許多機關在接受輔導後發現，建立良好的內部資料治理不僅有助於對外釋出資料，更能改善內部的工作流程。當資料被妥善組織和管理時，承辦人員在查找資訊、製作報告或回應上級交辦事項時，都能更加得心應手。這種內部效益往往是推動機關持續投入的重要動力。

ODC 為柬埔寨政府機關提供的資料識讀能力培訓，也展現了相同的邏輯。透過協助機關理解如何組織和管理資料，ODC 不僅降低了資料釋出的門檻，更提升了機關本身的行政效能。這個經驗說明，開放資料推動工作不應該被視為額外的負擔，而應該被理解為提升公務體系整體能力的契機。

5.2.2 賦能民眾的知情與參與

開放資料對民主的貢獻，不僅體現在透明度的提升，更體現在它如何讓民眾能夠更有效地參與公共事務。ODC 建立的經濟性土地特許權地圖就是一個典型案例。在這個地圖出現之前，柬埔寨的原住民社區很難了解哪些土地已被劃為特許區，哪些區域仍可供社區使用。當這些資訊以視覺化的方式呈現時，社區能夠具體地向政府倡議，要求保護傳統領域。然而當這些資料以 AI-Ready 格式釋出時，即使不具備專業法律或空間分析背景的公民，或許也能直接將結構化資料導入大型語言模型，快速摘要出特定開發案對其傳統領域的潛在影響，甚至要求 AI 生成針對該計畫的討論。

這種賦能帶來了具體的行動能力，並不抽象。當民眾能夠取得結構化的資料，他們可以進行自己的分析、提出有根據的質疑、或是發展替代方案。這種基於資料的公民參與，往往比純粹的情感動員更具說服力，也更能促成政策的實質改變。這種賦能讓民主參與從被動的知情轉向行動。當民眾能取得結構良好的原始資料，他們可以運用如 ChatGPT 等工具進行資料分析，將原本生澀的政府預算表或會議紀錄轉化為易於理解的白話文分析。

更重要的是，AI 與開放資料的結合徹底打破了公共參與的專業門檻。過去只有資深研究者或大型利益團體才有資源進行大規模的資料分析，現在任何一位具備基本提問能力的公民都能藉由人工智慧的輔助，與政府進行基於資料分析結果的對話。當開放資料不再只是靜態的網頁資訊，而是成為能被 AI 快速處理、分析與生成的內容時，不僅強化了公民的知情權，透明監督的力道將不再受限於資源的限制，也重塑了公民與政府間的權力平衡。

5.2.3 賦能 AI 的文化多樣性

當視角拉高到全球層次，開放資料對於 AI 發展的意義就不僅僅是技術問題，而是關乎文化保存與主權的根本議題。CroissantLLM 專案的目標就是打造一個真正雙語的法語模型，因為團隊觀察到市面上聲稱支援法語的模型，往往只是在以英語為主的訓練資料中摻入少量法語內容，導致模型在法語任務上的表現遠不如英語。

這個問題的嚴重性在於，如果一個國家的語言資料在訓練集中的佔比極低，該國在使用主流 AI 模型時將面臨被邊緣化與被錯誤解讀的問題。模型會傾向於輸出訓練資料中強勢文化的價值觀，如果歷史事件在模型中缺乏在地觀點的訓練語料，模型可能會根據外國媒體或帶有偏見的少數資料來解釋歷史，導致民眾對自身歷史的認知出現偏差。

ODC 的經驗更突顯了語言多樣性處理的複雜性。工作人員在訪談中指出，柬埔寨的語言障礙不僅僅是高棉語與英語之間的問題，還涉及眾多原住民族語言。如果資料只集中在城市或優勢語言，鄉村與原住民族的聲音就會在數位世界中消失。這種文化層面的不平等，將隨著 AI 應用的普及而更加嚴重。

政府在這個脈絡下的角色特別關鍵。當民間企業傾向蒐集具商業價值的資料時，政府更有責任釋出那些看似冷門、卻具備高度公共價值的資料，例如地方誌、方言紀錄或是偏鄉的基礎建設資料。這些資料或許無利可圖，但對於修正 AI 模型的文化偏見、建構具備在地主體性的數位環境而言，卻是不可或缺的關鍵拼圖。

German Commons 專案面對的時間偏見問題也提供了類似的啟示。由於著作權保護導致可用的文化作品多為歷史文獻，訓練出來的模型可能在語氣和用詞上顯得過時。這個問題雖然在現有法律框架下難以完全解決，但它亦提供了提醒與思考：政府應該如何調整著作權政策或資料釋出策略，才能確保當代文化也能被 AI 模型學習和傳承？

5.2.3 邁向可持續的開放資料生態系

當公務員發現開放資料能夠改善自己的工作效率時，他們會更願意投入這項工作。^[18] 當民眾能夠有效利用開放資料參與公共事務時，政府會感受到釋出資料的正面回饋。當 AI 模型能夠更準確地理解和生成在地語言與文化時，整個社會都能受益於更適切的數位服務。

西班牙資料總局局長 Carlos Alonso Peña Carlos 提到的文化轉變特別值得關注。他指出，推動開放資料最大的挑戰不是技術或法律，而是組織文化。當公務員害怕犯錯、擔心資料品質不夠好而遭到批評時，開放資料就會停滯不前。但如果能夠改變敘事框架，讓機關理解開放資料不是為了外部監督，而是為了內部改善，同時也是為了讓公民更好地參與，更是為了確保在地文化在 AI 時代不被邊緣化，那麼推動的阻力就會大幅降低。

從這個角度來看，開放資料邁向 AI 整合運用不只是技術升級，更關乎公務員能否更有效地服務民眾，民眾能否真正參與公共決策，還有一個國家的文化與語言能否在數位時代保有主體性。這三個面向的賦能共同構成了推動開放資料工作的深層意義，也是在面對各種技術和制度挑戰時，應該始終記得的初衷。

5.3 研究限制與未來展望

本份研究的執行期間為 2025 年 8 月至 12 月期間。這段時間全球的政府機關、公民團體或學術單位皆持續釋出更多基於開放資料的 AI-Ready 資料集，或者公布新的政策或研究成果。考量因專案時程限制，恐致個案收集與研究未臻完備，敬請海涵。

另本案多數個案研究皆依據第二和第三章的專案盤點及 TOE 象限藍圖挑選和呈現。惟呈上所述，各國在 AI 發展日新月異，因此在象限中的位置理論上也應動態移動，本報告礙於時程限制，僅能反映專案期間多數期間之情形。同時在第四象限，在高技術發展卻是低組織與環境脈絡成熟度的案例，也是相對缺乏的。

最後，本研究源於臺灣團隊，在過程中亦有訪談 6 位來自公部門、公民科技社群、AI 資料訓練家社群中的專家，其均有分別提出未來得以進一步訪談的臺灣案例，例如數位發展部在 9 月公告的 AI-Ready 的詮釋資料框架，給予臺灣政府機關更多提升資料品質及其描述的機會；同時 12 月底，數位部也正式釋出臺灣的主權 AI 訓練語料庫。此外，瑞士亦有在這期間釋出其專屬的主權 AI 資料集。這些均是本團隊期待未來得以進一步研究的。同時臺灣的公務機關亦有提出，針對臺灣案例得以如何進一步融合在地化的脈絡與國內公務員對話，則會建議有將部分案例亮點再發展出更多對應的懶人包或檢核表，這也未來本團隊希望對話發展方向。

5.4 總結

本報告期待，透過這些案例的書寫，能成為一面鏡子，幫助政府機關內的工作者理解自身角色。透過這些書寫、貼近實務的國際案例，每一個機關、每一位承辦人員，都能辨識自己當下所處的位置，理解即使仍在起步或面臨阻力，所做的努力依然具有公共價值。開放資料與 AI 並非只屬於技術單位或先行者，而是所有參與公共服務的人，都能逐步投入、逐步累積的共同工程。

同時，也期待這份成果能成為政府與民間之間的「溝通材料」。對於 NGO 與公民科技社群而言，在面對不同成熟度、不同知識背景政府機關時，能夠以具體案例說明「可以怎麼開始」、「別人是怎麼走過來的」，以及「哪些路徑是可行且可調整的」。這樣的對話，將不再停留在抽象的理念倡議，而是建立在實際經驗與可落地行動之上。

也邀請後續研究者與政策制定者，將這些案例視為持續對話的起點。隨著 AI 技術、法規環境與社會期待不斷變化，開放資料的治理模式勢必需要持續修正與再設計。唯有在政府、學界與公民社群之間建立長期的合作與回饋機制，這套生態系才能穩健成長。更多人能在這條路上看見自己的位置、理解彼此的限制與專業，開放資料才會真正成為一項可持續的公共基礎建設。這不是某一方的責任，而是一場需要被共同承擔、也值得被共同完成的集體行動。



18. Kleiman, Fernando, Marijn Janssen, Sebastiaan Meijer, and Sylvia J. T. Jansen. "Changing Civil Servants' Behaviour Concerning the Opening of Governmental Data: Evaluating the Effect of a Game by Comparing Civil Servants' Intentions before and after a Game Intervention." *International Review of Administrative Sciences*, 2022. <https://doi.org/10.1177/0020852320962211>.